連合学習を用いた企業デジタル化要素の因果構造推定

CAUSAL STRUCTURE ESTIMATION OF CORPORATE DIGITALIZATION FACTORS USING FEDERATED LEARNING

李 星宇
Xingyu LI
指導教員　劉 慶豊

法政大学大学院理工学研究科システム理工学専攻専攻修士課程

Digital transformation (DX) has evolved from IT adoption into a continuous, strategy-driven process that reshapes organizational structure, data utilization, human capital, and governance. This study conceptualizes DX-related investments as interdependent strategic elements and examines their structural relationships using causal structure learning. Based on text data from publicly available annual reports from CNINFO, we estimate a sparse directed acyclic graph (DAG) under a linear Gaussian structural equation model within a federated learning framework, allowing distributed estimation without sharing raw data. The resulting causal network reveals a layered structure of DX elements, distinguishing upstream foundational capabilities, mediating components, and downstream implementation or outcome-oriented elements. The analysis also identifies complementary and substitutive relationships among DX domains and clarifies directional pathways and relative influence strengths. By shifting the focus from isolated performance effects to structural sequencing and interaction logic, this study provides an interpretable roadmap for prioritizing DX initiatives. The findings offer practical guidance for Small and Medium-sized Enterprises (SMEs) under resource constraints and inform policymakers on the design and sequencing of digital support policies.

Key Words *: Digital Transformation, Causal Discovery, Directed Acyclic Graphs, Federated Learning*

１．はじめに

近年，デジタル技術の普及は企業活動の価値創出や競争環境を大きく変化させ，DX は単なる IT 導入ではなく，戦略・組織・人材・ガバナンス・データ活用を含む継続的な変革として位置づけられている[1]．しかしながら，実務では「どの領域から着手し，どのような順序で能力を蓄積すべきか」という問いがなお解けていない．とりわけ経営資源の制約が顕著な中小企業（SMEs）においては，投資余力や人材不足に加え，部門間の利害調整や成果指標の乖離が実行を阻害する要素となりやすい[2]．そのため，政策的支援の側面からも，支援の優先順位の構造的な整理が強く求められている．既存研究は DX 関連要素と成果の関連を示してきたが，相関・回帰中心の分析では交絡や逆因果の可能性が残り，複数要素の先後関係や経路を統合的に捉えにくい[3]．加えて，相乗効果とトレードオフが同時に生じ得る状況で，意思決定に接続できる形で全体構造を提示する枠組みは十分に整備されていない[4]．そこで本研究は特定の DX 要素への注力が他の要素へ及ぼす連鎖反応を「戦略的関心ロジック」として可視化し，その構造的メカニズムを解明することを目指す．具体的には，公開年次報告書から抽出した DX 関連語彙の出現頻度を，経営層の関心を反映する代理変数として定量指標化した．方法としては，線形ガウス DAG に基づく因果構造学習を適用し，DARLS（Distributed Annealing on Regularized Likelihood Score）の分散 DAG 学習の枠組みを参照しつつ[5]，分散環境を想定した連合学習型の集約と反復推定による安定性選択を組み合わせることで，再現性と頑健性の高い因果ネットワークを導出した．

２．データと変数設計

（１）データ概要

本研究は，中国の上場企業が法定開示義務に基づき作成する年次報告書を分析の基盤として用いる．年次報告書は，投資家の意思決定に資する情報の真実性・正確性・完全性・適時性が制度的に担保された公式文書である[6]．このため，同文書には企業の経営戦略，投資計画，組織運営に関する体系的な記述が含まれており，企業の「戦略的関心」を抽出する上での信頼性の高いテキストデータと

見なすことができる．データの取得にあたっては，深圳証券取引所の法定情報開示プラットフォームである CNINFO を使用する．同プラットフォームは公開性と網羅性の観点から極めて優れており，大規模な企業テキストデータを比較可能な形式で一括取得することが可能である．本研究の分析単位は「企業×年度」とし，対象年度は 2024 年度とする．最終的な有効企業サンプルは $N = 5091$ 社である．年次報告書は文書長のばらつきが大きいため，総語数の分布を確認する（図 1）．これは，後続の因果構造学習において，テキスト量そのものがバイアス要因とならないようにするためである．

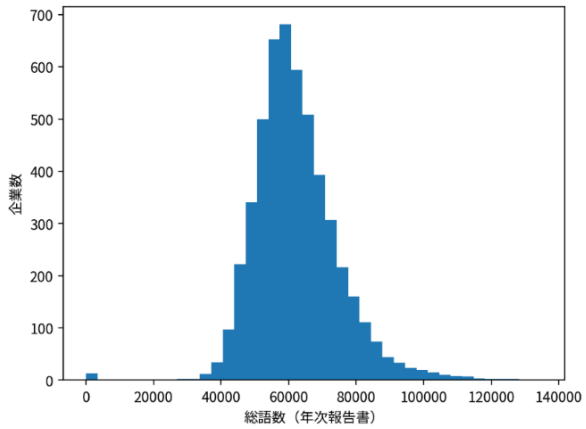

図 1：総単語履歴

（２）テキスト前処理

本研究は，年次報告書（PDF 形式）から抽出された非構造化テキストを経営者の「戦略的関心」を反映する代理変数として用いるため，以下の前処理パイプラインを構築した．まず，CNINFO より企業別の PDF ファイルを収集し，取得時のレスポンスを確認することで非該当ファイルの混入を排除した．次いで，pdfplumber を用いて本文テキストをページ順に抽出し，論理的な一貫性を保つ形で連結・保存した．つづいて，正規表現により数値・英字・記号等の中国語以外の要素を除去し，空白・改行を整形した．中国語の分かち書きには jieba を用い，DX 関連語彙をユーザ辞書として登録して分割誤りを抑制した．最後に，前処理済みテキストに対し，事前に定義した語彙の出現回数を企業ごとに集計して語彙頻度表を作成した．これにより，定性的な経営報告を計量的な分析が可能な連続指標へと変換し，次章以降の因果構造学習における入力データとして整備した．

（３）デジタル化要素の定義

本研究では，年次報告書テキストに表出する企業のデジタル化に関する記述を DX への戦略的関心として捉え，その強度を多面的に把握するために 10 個のデジタル化要素を定義する．そこで，先行研究および実務的な DX の進展を踏まえ，表 1 に示す 10 のデジタル化要素を定義した．各要素は，DX 変革全体を構成する相互依存的なサブシステムとして位置づけられる．

表 1:デジタル化要素の定義

因子	概念的定義
デジタル戦略・能力（DS）	デジタル化を経営戦略として位置づけ，方針・ロードマップ・全社能力として統合する記述の強度．
技術革新・研究開発（TI）	新技術の探索・研究開発・製品/プロセス革新に関する記述の強度．
生産・運用効率（PO）	業務プロセスのデジタル化，自動化，スマート化等による運用改善に関する記述の強度．
財務パフォーマンス（FP）	収益性，コスト，投資負担等，財務成果に関する記述の強度．
市場パフォーマンス・顧客（MP）	顧客価値，市場開拓，チャネル，サービス高度化等に関する記述の強度．
人材・従業員育成（TS）	デジタル人材，技能育成，組織学習，働き方の変化等に関する記述の強度．
IT 投資（IT）	情報システム，インフラ，クラウド等への投資・導入に関する記述の強度．
組織ガバナンス・管理変革（OG）	組織構造，意思決定，管理制度，ガバナンス改革等に関する記述の強度．
政策・規制環境（PR）	デジタル関連政策，規制対応，標準・コンプライアンス等に関する記述の強度．
データ活用・分析能力（DA）	データ基盤，分析と可視化，AI 活用，データ駆動意思決定等に関する記述の強度．

操作的には，各因子 j に対応づけたキーワード辞書を $\mathcal{D}_j$ とし，企業 i の年次報告書テキストにおける語 w の出現回数を $\mathrm{count}_i(w)$ とおく．このとき，企業 i の因子 j の強度 $X_{i,j}$ を次式で定義する．

$$X_{i,j} = \sum_{w \in \mathcal{D}_j} \mathrm{count}_i(w) \tag{1}$$

本研究では強度の基底として原始頻度を用い，後続節にて log 変換および列方向標準化を行うことで，因子間で比較可能な連続強度データへ変換する．

（４）指標化手順

年次報告書テキストから得られる因子別語頻 $X_{i,j}$ を

線形ガウスモデルに基づく因果構造学習へ接続するため，本研究では原始語頻を集計した後に log 変換を施し，最後に列方向の z-score 標準化を行うことで，比較可能な連続指標として変換した．語頻は非負であり，企業間でヘビーテイルをとりやすい．少数の企業が非常に大きな値をとることにより，そのまま線形モデルへ投入すると外れ値の影響が大きくなり，推定の安定性や解釈可能性を損なう恐れがある．そこで本研究では，0 を含む非負の語頻 $X_{i,j}$ に対して外れ値の影響を緩和し分布の歪みを抑えるため，次式で定義される log 変換を適用する[7]．

$$X_{i,j}^{(\log)} = \log\left(1 + X_{i,j}\right) \tag{2}$$

次に，因子ごとのスケール差を除去し，係数の比較可能性を確保するため，因子 j ごとに列方向の z-score 標準化を行う．企業数を N とし，log 変換後の列について標本平均 μ_j と標本分散 s_j^2 を次式で定義する．

$$\mu_j = \frac{1}{N}\sum_{i=1}^{N} X_{i,j}^{(\log)}, s_j^2 = \frac{1}{N-1}\sum_{i=1}^{N}\left(X_{i,j}^{(\log)} - \mu_j\right)^2 \tag{3}$$

このとき標準化変数 $Z_{i,j}$ を次式で与える．

$$Z_{i,j} = \frac{X_{i,j}^{(\log)} - \mu_j}{s_j} \tag{4}$$

以上により，すべての因子は平均 0・分散 1 を持つ単位なしの尺度にそろい，因子間で同一基準の比較が可能となる．なお，全体標準化に必要な平均・分散は連合学習環境下で要約統計量を集約して算出する．

（５）クライアント分割の設定

本研究は，将来的に企業データが複数主体に分散し，制度的あるいは運用上の制約から生データの集中管理が困難となる状況を想定し，連合学習環境を模擬したクライアント分割設定を導入する．具体的には，全サンプル数を $N = 5091$ とし，これを $K = 20$ の仮想的なクライアントに分割し，各クライアント k が保持するローカルデータを $\mathcal{D}_k$ と定義する．観測単位は「企業×年度」であり，前節までに構成した標準化後の因子行列を分散データとして扱う．各クライアントは自らのローカルデータを外部に開示することなく，後続の因果構造推定に必要な中間計算のみを実行し，サーバには最小限の統計要約量のみを送信する非中央集権的な計算パラダイムを採用する．これにより，公開データを用いた再現性の高いテストベッドとしての機能を維持しつつ，実務上の分散・プライバシー配慮型分析への拡張性を担保する実装上の整合性を確保した．

（６）記述統計と基礎可視化

本節では，構成した 10 因子の分布特性を把握し，後続の因果構造推定に影響し得るデータの特徴を整理する．まず，因子別語頻の記述統計を表 2 示すことで，因子間で分布のスケールや歪度，零比率が大きく異なることを確認する．一部の因子においては高い零比率が観察され，特定の DX 要素に対する「言及の有無」自体が企業間で明確に分かれることが示唆される．その一方で，別の因子では多くの企業が一定の関心を示しており，言及の強弱が連続的な差異として表出している．このような分布の異質性は，企業の戦略的関心が一様ではないことを示唆しており，因果構造学習においても差異情報として重要である．

表 2：因子別語頻の記述統計（N=5091）

因子	平均	標準偏差	最大	零比率
DS	9.0	20. 25	451	17. 4
TI	15. 3	8. 78	131	0. 7
PO	9. 1	27. 38	648	14. 0
FP	117. 6	22. 33	774	0. 2
MP	5. 3	10. 28	320	11. 0
TS	1. 6	1. 68	24	29. 5
IT	2. 3	12. 89	366	62. 1
OG	35	12. 08	104	0. 3
PR	1. 2	1. 65	20	44. 7
DA	1. 4	3. 47	108	49. 5

次に，因子別の零比率を図 2 に可視化し，高零比率を呈する特定の因子を明示する．零比率が顕著に高い因子は，単に「戦略的関心」の強度が低いことを示す．

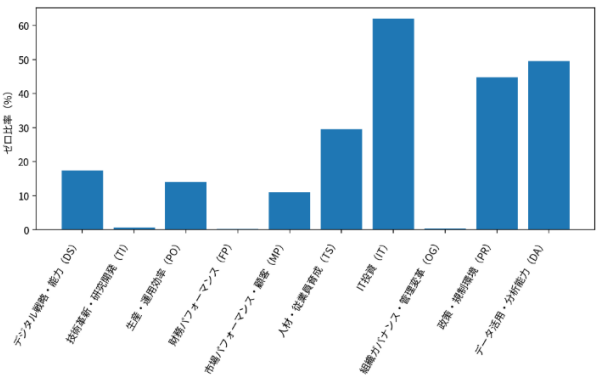

図 2: 因子別の零比率

さらに，log 変換後の分布を箱ひげ図（図 3）で可視化

し，外れ値の影響がどの程度緩和されたかを確認する．原始スケールにおける語彙頻度は著しい歪度を呈しており，そのままでは線形ガウスモデルの基本仮定との整合性を損なう恐れがある．しかし，log 変換を適用した結果，多くの因子において極端値の圧縮が確認された．これにより，後続の z-score 標準化と併せて，統計的に扱いやすいデータ形状を確保できる．

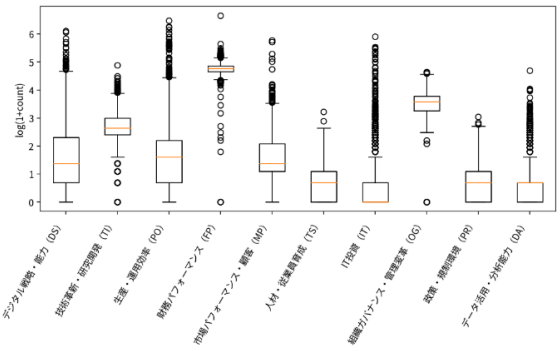

図 3: log 変換後の分布を箱ひげ図

３． 方法論

本研究の推定手順の全体像を図 4 に示す．分散環境を想定し，候補 DAG の評価（局所回帰）と順序探索（Actor–Critic）を反復し，出現頻度に基づく安定性選択で最終構造を確定する．

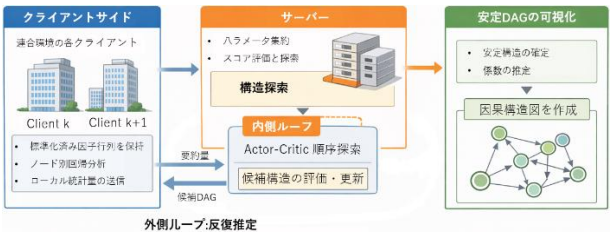

図 4: 方法論フレームワーク図

（１）線形ガウス DAG モデルの定式化

本ノード集合を $V = \{1, \ldots, p\}$とし，標準化済み因子を $Z_{i,j}^{(k)}$ と表す．本研究では，DAG $\mathcal{G}$ の下で各ノード j は，その親ノード集合 $\mathrm{Pa}_{\mathcal{G}}(j)$ に条件づけられると仮定し，線形ガウス SEM を次式で定式化する．

$$Z_{i,j}^{(k)} = \beta_{0j} + \sum_{u \in \mathrm{Pa}_{\mathcal{G}}(j)} \beta_{uj} Z_{i,u}^{(k)} + \varepsilon_{i,j}^{(k)}, \varepsilon_{i,j}^{(k)} \sim \mathcal{N}(0, \sigma_j^2) \quad (5)$$

この定式化により，特定のグラフ構造 $\mathcal{G}$ が与えられた条件下では，各ノード j の推計は，親ノードを説明変数とする局所的な回帰問題として評価することが可能となる[8]．すなわち，候補構造ごとにノード別回帰を行い，残差平方和（RSS）に基づいて適合度を計算することで，全体構造の良さを比較する．線形ガウスモデルを採用する最大の利点は，誤差分散 σ_j^2 を推定しつつ，負対数尤度（NLL）によって各ノードの適合度を個別に測定できる点にある．この性質は，連合学習型の集約や探索アルゴリズムにおいて，局所的な評価値の総和によって全体スコアを構成できるという，計算上の高い整合性を提供している．

（２）連合学習

本研究では，全データを K 個（$K = 20$）のクライアントに分割し，クライアント k は自身のローカルデータ D_k のみを保持する非中央集権的な設定を採用する．サーバは候補構造を配布し，クライアントは各ノード j について親集合に対応する設計行列を用いてローカル回帰を実行する．この際，生データを共有することなく，局所的な損失関数とパラメータ集約に必要な統計要約量のみをサーバへ返送する設計としている．また，推定構造の過密化を抑制し，因果経路の解釈可能性を高めるため，本研究ではノード別回帰に L1 正則化（Lasso）を導入し，親ノード候補の自動選択を行う．これにより，連合学習の枠組みにおいて，係数レベルでのスパース性を担保しつつ構造推定を行うことが可能となる．具体的に，クライアント k におけるノード j の推定問題は，以下の正則化尤度最小化として定式化される．

$$\min_{\tilde{\beta}_j} \frac{1}{2n_k} \left\| y_j^{(k)} - \tilde{X}_j^{(k)} \tilde{\beta}_j \right\|_2^2 + \alpha \left\| \mathrm{P} \tilde{\beta}_j \right\|_1 \quad (6)$$

ここで $y_j^{(k)}$ はノード j の目的変数，$\tilde{X}_j^{(k)}$ は候補親ノード集合から構成される設計行列である．サーバ側では，各クライアントが返送された局所損失を合算して全体損失を構成し，候補構造を比較する．本研究における全体スコアは，モデルの適合度とスパース性のトレードオフとして定義し，探索ではこのスコアを最小化する目的関数を次式で与える．

$$\mathrm{Score}_{\mathrm{BIC}}(\mathcal{G}) = \sum_{k=1}^{K} \sum_{j=1}^{p} \mathrm{NLL}_j^{(k)} + \mathrm{Pen}(\mathcal{G}) \quad (7)$$

ここで，$\mathrm{Pen}(\mathcal{G})$ はスパース性対するペナルティ項であり，辺数ペナルティ $\lambda|E(\mathcal{G})|$ または BIC（ベイジアン情報規定）の規準などを用いて過密な構造を抑制する．これにより，過剰に複雑なモデルを排し，データへの適合度と解釈性を両立した疎な DAG の選択が可能となる．さらに，クライアント間で推定された係数を統合し，グローバルなパラメータを導出する際には，サンプル数重みでの平均（FedAvg）を用い，分散設定でも全体として一貫したパラメータ更新が可能になる[9]．

$$\hat{\boldsymbol{\beta}}_j = \sum_{k=1}^{K} (n_k / N) \hat{\boldsymbol{\beta}}_{k,j} \quad (8)$$

以上の設計により，サーバは生データを直接参照することなく，分散環境下においても全体として一貫したパラメータ更新と構造評価を実行できる．

（３）DAG 構造の学習

DAG 構造探索は組合せ最適化であり，単純な全探索は現実的でない．そこで本研究では，順序 π を探索し，順序に整合する向きのみを許して候補 DAG を生成する」という順序ベースの枠組みを採用する．順序を介することで非循環性を直接担保でき，探索空間を体系的に扱える．順序探索を強化学習の枠組みで定式化するため，環境をマルコフ決定過程（MDP）として定義する．すなわち，状態 s_t は現在の順序 π_t を表す表現（例：順列行列をベクトル化したもの）とし，行動 a_t は順序は順序 π_t に対して 2 つの位置 p, q（$1 \le p < q \le |V|$）を選び，それらを入れ替える操作として定義する．行動実行後，環境は新しい順序 π_{t+1} を返し，それに対応するスコア $\mathrm{Score}(\mathcal{G}(\pi_{t+1}))$ を再計算する．報酬は改善度として

$$r_t = \mathrm{Score}(\mathcal{G}(\pi_t)) - \mathrm{Score}(\mathcal{G}(\pi_{t+1})) \tag{9}$$

と定義し，スコアが小さくなるほど正の報酬を得る設計とする．

本研究では，DARLS の枠組みにおける「構造探索（順序更新）」プロセスを拡張し，従来の焼きなまし（Simulated Annealing）に代えて Actor–Critic 型強化学習による探索を導入する[10]．焼きなましは温度スケジュール等の設定に探索挙動が強く依存するという課題があった．これに対し，Actor–Critic は探索方針を学習を通じて適応的に更新できるため，分散・非 IID 環境における探索の安定化と効率化を図りやすいと考えられる．具体的には，行動方策 $\pi_\theta(a_t \mid s_t)$ を出力する Actor と，状態価値 $V_\phi(s_t)$ を推定する Critic を同時に学習するアルゴリズムを構築する．収集した系列 $\{(s_t, a_t, r_t)\}$ から割引報酬 $G_t = \sum_{\tau=t}^{T-1} \gamma^{\tau-t} r_\tau$ を計算し，アドバンテージ関数を $A_t = G_t - V_\phi(s_t)$ によって近似する．

Actor 損失関数

$$\mathcal{L}_{actor}(\theta) = -\sum_{t=0}^{T-1} log\, \pi_\theta\,(a_t \mid s_t)\, A_t \tag{10}$$

を最小化し，Critic 損失関数

$$\mathcal{L}_{\mathrm{critic}}(\phi) = \sum_{t=0}^{T-1} \left(V_\phi(s_t) - G_t\right)^2 \tag{11}$$

を最小化するように更新する．

この学習プロセスを通じて，Actor は高い報酬（より適合度の高いスパースな DAG 構造）をもたらす行動を選択するように方策を改善し，Critic はその評価の精度を高めることで，複雑な探索空間における最適構造への収束を支援する．

構造探索のプロセスは，二重の制約条件によって制御される．第一に，各エピソード内では最大ステップ数 $\mathrm{T_{max}}$ に達した時点でエピソードを終了する（done = 1）．第二に，全体では最大エピソード数 $\mathcal{E}_{\max}$ に達した時点で学習を終了する．学習過程では，各ステップで得られるスコア $\mathrm{Score}(\mathcal{G}(\pi))$ を監視し，これまでの最小値を与える順序 π^* と構造 $\mathcal{G}^* = \mathcal{G}(\pi^*)$ および係数推定値を保持する．最終的に，保持された $\mathcal{G}^*$ を推定因果構造として出力する．因果 DAG の構造学習は，サンプル変動，正則化強度，探索初期値などの影響を受けやすく，単回推定の結果のみを最終結論とすることは過剰な確信を招き得る．そこで本研究では，データ摂動に基づく反復推定を行い，推定されたエッジの出現頻度を用いて構造の信頼性を評価する．

因果構造学習は，サンプルの揺らぎや探索の初期値・乱数により推定結果が変動し得る．そこで本研究では，データ摂動と探索乱数の変更を伴う反復推定を R 回行い，エッジの再現性に基づいて最終構造を確定する．反復 R で得られたエッジ集合を $\hat{\mathcal{E}}^{(r)}$ とすると，エッジ $u \to j$ の出現頻度は次式で与えられる．

$$\pi_{u\to j} = \frac{1}{R}\sum_{r=1}^{R} \mathbf{I}\left(u \to j \in \hat{\mathcal{E}}^{(r)}\right) \tag{12}$$

最終的な信頼性付き推定構造を，出現頻度閾値 π_0 により定義する．すなわち，

$$\hat{\mathcal{E}}_{\mathrm{stable}} = \left\{(u \to j) \,\middle|\, \pi_{u\to j} \ge \pi_0 \wedge \pi_{u\to j} > \pi_{j\to u}\right\} \tag{13}$$

とし，$\hat{\mathcal{G}}_{\mathrm{stable}} = \left(V, \hat{\mathcal{E}}_{\mathrm{stable}}\right)$ を最終図として報告する．

（４）構造確定後の強度推定と解釈

本安定性選択により最終構造 $\hat{\mathcal{G}}_{\mathrm{stable}}$ を確定した後，本研究では強度推定を別段階で行う．構造学習段階では L1 正則化や剪枝により過密化を抑えるが，係数には収縮バイアスが生じやすく，そのまま影響量として解釈するのは適切でない．そこで，確定構造上で親集合 $\mathrm{Pa}_{\hat{\mathcal{G}}_{\mathrm{stable}}}(j)$ を固定し，ノード j ごとに OLS で係数を再推定する．

$$\hat{\tilde{\beta}}_j = \left(\tilde{\boldsymbol{X}}_j^\top \tilde{\boldsymbol{X}}_j\right)^{-1} \tilde{\boldsymbol{X}}_j^\top \boldsymbol{y}_j \tag{14}$$

連合学習設定では，クライアント k の局所データに対し，$\boldsymbol{S}_{\mathrm{xx}}^{(k)} = \tilde{\boldsymbol{X}}_j^{(k)\top} \tilde{\boldsymbol{X}}_j^{(k)}$，$\boldsymbol{S}_{\mathrm{xy}}^{(k)} = \tilde{\boldsymbol{X}}_j^{(k)\top} \boldsymbol{y}_j^{(k)}$ を計算し，サーバは $\boldsymbol{S}_{\mathrm{xx}} = \sum_{k=1}^{K} \boldsymbol{S}_{\mathrm{xx}}^{(k)}$，$\boldsymbol{S}_{\mathrm{xy}} = \sum_{k=1}^{K} \boldsymbol{S}_{\mathrm{xy}}^{(k)}$ を集約する．すると，

$\hat{\beta}_j = \boldsymbol{S}_{\mathrm{xx}}^{-1}\boldsymbol{S}_{\mathrm{xy}}$ によりグローバル係数が得られる．本研究の因子は z-score 標準化済みであるため，エッジ係数 $\hat{\beta}_{u\to j}$ は「因子 u が 1 標準偏差増加したとき，因子 j が $\hat{\beta}_{u\to j}$ 標準偏差変化する」条件付き直接効果として比較可能である．さらに，経路の積として総効果を評価することで，媒介を含む波及の大きさも整理できる．

$$\mathrm{TE}_{u\to j} = \sum_{p\in\mathcal{P}_{u\to j}} \prod_{(a\to b)\in p} \hat{\beta}_{a\to b} \tag{15}$$

以上により，再現性の高い関係と比較可能な影響量を分離して提示する．

４．分析結果

本章では，線形ガウス DAG により推定した 10 要素の因果ネットワークについて，推定結果の全体像と係数の特徴を整理する．まず，安定性選択の主設定に基づく安定構造を提示し，以降の図表・解釈が同一基準の下で行われることを明確にする．次に，入次数・出次数，下流影響強度等の指標により各要素の上流／下流の位置づけを定量的に示し，トポロジカル層別により DX 推進順序をロードマップとして解釈する．さらに，財務パフォーマンス（FP）に着目して直接効果の要点を抽出し，最後に互補（正）／代替（負）の関係整理を通じて実務・政策的含意と限界を述べる．

（１）安定構造の確定

安定性選択のプロセスでは，反復推定で得られる各エッジの出現頻度 π を用い，あらかじめ設定した閾値 π_0 以上で再現される関係のみを安定エッジとして採択する．本研究では，π_0 を 0.60 から 0.90 の範囲（試行回数 R=50）で変動させた感度分析の結果に基づき，構造の疎性（解釈のしやすさ）と再現性のの最適な均衡点を精査した。その結果，ノード間の本質的な連鎖を抽出しつつ，推計の頑健性を確保し得る主設定として $\pi_0 = 0.70$ を採用した．

表 3:安定性選択における π_0 の比較（R=50）

π_0	エッジ数	正辺数	負辺数	平均出現頻度
0. 6	15	13	2	0. 83
0. 7	14	13	1	0. 84
0. 8	9	9	0	0. 90
0. 9	6	6	0	0. 94

表 3 に示すように，π_0 の上昇に伴い安定エッジ数は減少して構造はより疎になる一方，残存エッジの平均出現頻度は上昇し，統計的な再現性が向上する．加えて，因果ネットワークの解釈可能性をさらに高めるため，安定エッジ集合に対して条件付き平均係数 $|\bar{\beta}|$ に基づく追加剪枝（閾値 t）を感度分析として行った．

表 4:閾値感度（$\pi_0 = 0.7$ 固定）

t	エッジ数	正辺数	負辺数	平均出現頻度
0. 00	14	13	1	0. 837
0. 03	14	13	1	0. 837
0. 05	14	13	1	0. 837
0. 07	13	12	1	0. 840
0. 10	8	8	0	0. 863

表 4 の通り，t を高めるほどエッジ数は減少し，強い関係に焦点化した骨格構造が得られる（例：$t = 0.100$では 8 本まで縮退）．本章の主要解釈は $\pi_0 = 0.70$ の安定構造を基本とし，図示の目的に応じて t で密度を調整する．

（２）推定因果ネットワークの全体像と解釈

図 5 は，安定性選択により採択された DAG（剪枝済み）の全体像を示す．

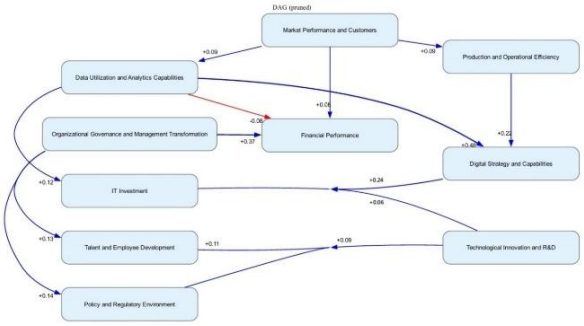

図 5:安定性選択に基づく推定因果ネットワーク

安定構造に含まれるエッジは 14 本であり，正のエッジが 13 本，負のエッジが 1 本であった．本ネットワークの骨格は正の関係（互補）を中心に形成され，負の関係（代替）は限定的に観察される．このことは，DX 関連要素が「同時に強まりやすい連鎖」として語られやすい一方で，特定局面では注意・資源配分の競合が生じ得ることも示唆する．矢印は因果方向（上流→下流）を表し，エッジ重みは標準化係数 β として解釈する．すなわち，「要素 X が 1 標準偏差増加したとき，要素 Y が平均的に β 標準偏差変化する」程度を意味する．推定結果を解釈する際には，入次数 0 の上流ノードとして起点となりやすい要素，中間ノードや経路として連鎖を媒介する要素，および下流ノードとして成果・実装が集約される要素に着目する．これにより，DX を個別施策の羅列ではなく，要素間の関心の連鎖として整理できる．

（３）データ指標に基づく上流・下流構造の整理

上流／下流の判定を図の印象に依存させないため，本研究では推定 DAG から算出される入次数・出次数，媒介中心性，下流影響強度（当該ノードから出る係数絶対値の総和），および反復推定に基づく平均出現頻度（平均π_{out}，平均π_{in}）を用いて構造的位置づけを整理した．

表 5 より，OG・MP・TI はいずれも入次数 0 で，他要

素から直接の影響を受けない上流（前置能力）として位置づけられる．とりわけ OG は出次数が大きく，下流へ広く波及し得る統治要素として解釈できる．中間層では，DA の媒介中心性と下流影響強度が最大であり，上流の関心を具体的施策へ接続する橋渡しになりやすい．PO および DS も中間層として媒介性を持ち，運用改善（PO）と戦略の言語化（DS）が関心の連鎖を実装へ導く結節点として働く可能性が示された．下流（結果層）では PR・TS・FP・IT が出次数 0 で，複数の前置要素がそろった後に制度対応・人材・成果・投資として現れやすい．

表 5:上流・下流指標

要素	媒介中心性	下流影響強度	π_{out}	π_{in}	位置
OG	0. 000	0. 641	0. 880	−	上流
MP	0. 000	0. 267	0. 827	−	上流
TI	0. 000	0. 267	0. 767	−	上流
DA	0. 021	0. 683	0. 820	0. 94	中間
PO	0. 007	0. 216	0. 940	0. 84	中間
DS	0. 014	0. 243	0. 900	0. 86	中間
PR	0. 000	0. 000	−	0. 87	下流
TS	0. 000	0. 000	−	0. 72	下流
FP	0. 000	0. 000	−	0. 80	下流
IT	0. 000	0. 000	−	0. 88	下流

さらに，DAG の非巡回性を用いてトポロジカル順序を構成すると，DX における関心の先後関係を段階の物語として読み替えられる．図 6 は層別結果を示しており，統治（OG）・市場（MP）・研究開発志向（TI）を起点として，運用（PO）とデータ活用（DA）の整備が進み，それを踏まえて戦略（DS）が言語化され，最終的に IT 投資（IT）として実装に至るという現実的なロードマップとして整理できる．

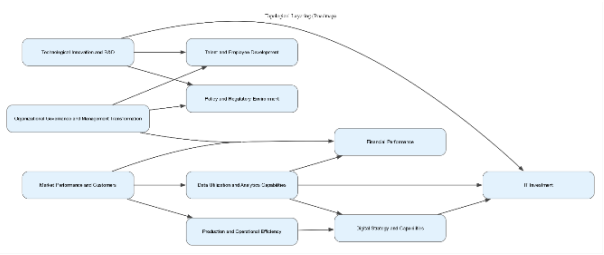

図 6:トポロジカル層別による DX 因果ロードマップ

（４）FP を中心とした直接的影響構造と実務的含意

企業が最も関心を持つ指標として財務パフォーマンス（FP）を例に取り，FP に直接影響する要素のみを抽出して可視化した．図 7 が示す通り，FP への直接影響は OG・MP・DA の 3 要素に限定される．

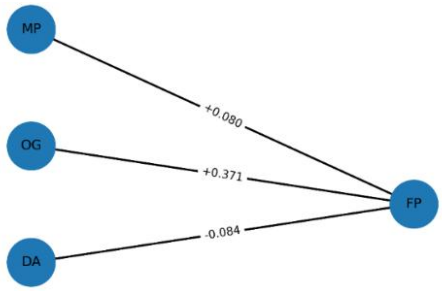

図 7:FP に対する直接的影響構造

まず OG→FP の正の影響は，DX が財務成果へ結びつくか否かが，経営レベルの統治や意思決定の枠組みに大きく依存することを示唆する．DX を現場の改善活動にとどめることなく，投資判断・権限配分・評価指標に組み込み，経営のアジェンダとして継続的にモニタリングすることが前提条件となる．

次に MP→FP の正の影響は，市場・顧客からの要請が財務成果の重要な起点であることを示す．顧客期待（品質・納期・サービス）への対応は，価格戦略やコスト構造の見直しを通じて財務指標へ反映されやすく，DX を外部関係の再設計として捉える視点が重要となる．

一方で DA→FP は負の係数であり，データ基盤整備や分析能力への投資が短期的には財務成果を直接押し上げない可能性を示す．

実務では，データ整備・人材育成・分析の試行錯誤は先行投資として発生しやすいため，短期 KPI のみで評価するとデータ投資の正当化が困難になる．したがって，効果の時間差を前提に，短期の運用 KPI と中長期の成果 KPI を分けて設計し，ガバナンスの下で段階的に投資を回収していく運用が求められる．

（５）互補・代替関係，実務・政策への含意

図 8 と図 9 は正負エッジを分離して可視化したものである．正のエッジは互補関係として，負のエッジは限られた注意・資源配分のもとで重点が入れ替わる代替関係として解釈できる．

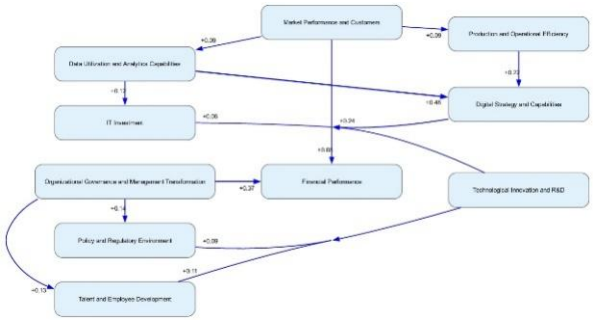

図 8:正エッジの可視化

実証結果は，変革の起点が市場（MP）にあり，データ活用（DA）や運用改善（PO）を経て戦略（DS）が言語化され，最終的に IT 投資が合理化されるという「後追い型の実装プロセス」を浮き彫りにした．これは，先に統治，データ，運用の土台を整えることが，投資失敗を避ける実務的要諦であることを示唆している．

この構造的知見は，中小企業支援および政策設計に重要な示唆を与える．従来の政策は，下流の「IT 導入補助」に偏りがちであったが，本結果はガバナンス（OG）や市場対応（MP）といった上流の「前置能力」こそが連鎖の起点であることを示している．したがって，単発のツール導入支援に加え，統治体制の整備伴走，データリテラシー研修，運用改善支援をパッケージ化して提供することが，持続的な DX 推進には不可欠である．

図 9:負エッジの可視化

また，OG が財務（FP）や人材（TS）と連動する一方，DA→FP に負の関係（β=-0.084）の 1 本のみが安定的に観察された．これは，データ基盤整備や分析能力への関心が高まる局面で，短期の財務成果（FP）への関心が相対的に後景化し得る，という可能性を示すシグナルである．実務的には，DX を“短期の財務 KPI だけで測り切ろうとする”と，データ整備フェーズの投資や試行錯誤が評価されにくくなるため，フェーズに応じた KPI 設計が重要となる．

５．まとめと今後の課題

本研究は，企業の DX を単一の技術導入や断片的な成果指標の集合としてではなく，経営層の多面的な戦略的関心が相互に連鎖・波及する因果構造として捉え直すことを目的とした．

方法論面では，中国上場企業の年次報告書から抽出した 10 要素を代理変数として，線形ガウス DAG により方向・経路・符号・強度を同時推定した．さらに DARLS を踏まえ，焼きなまし法による探索を Actor–Critic 型強化学習へ刷新し，分散・非 IID 環境下でも方針を自律更新できる枠組みに安定性選択を統合することで，解釈可能性と再現性を担保した分析パイプラインを提示した．

実証面では，推定因果ネットワークから DX 要素が上流・中間・下流の多層構造を形成することを示し，SMEs や支援設計における着手順序の参照枠を与えた．

今後は，企業データのパネル化による時間構造の導入を進めるとともに，外部定量指標との統合を通じて測定妥当性を検証し，さらに非線形性や異質性を考慮した推定枠組みへの拡張が考えられる．加えて，セキュア集約等を含む連合学習の実運用条件下での検証を行い，より実務に接続した因果推定へ発展させる．

謝辞：長い間に温かく見守り，沢山のご指導を賜った指導教員の劉 慶豊先生に厚く御礼を申し上げ，感謝の意を表します．ご助言を賜った副査の劉 子昂先生に深謝申し上げます．最後にデータサイエンス＆計量経済学研究室の皆様に感謝いたします．

参考文献

[1] OECD. (2021). The Digital Transformation of SMEs. *OECD Studies on SMEs and Entrepreneurship*. https://doi.org/10.1787/bdb9256a-en

[2] Liu, J., Wang, J., & Hu, Q. (2025). A Systems Perspective on Corporate Social Responsibility Decoupling and Investment Efficiency: Evidence from Chinese Listed Firms.*Systems*,*13*(9). https://doi.org/10.3390/systems13090833

[3] Peters, J., Janzing, D., & Schölkopf, B. (2017). *Elements of Causal Inference: Foundations and Learning Algorithms*.MITPress. https://mitpress.mit.edu/9780262037310/elements-of-causal-inference/?utm_source=chatgpt.com

[4] Zheng, X., Aragam, B., Ravikumar, P., & Xing, E. P. (2018). DAGs with NO TEARS: Continuous Optimization for Structure Learning (arXiv:1803.01422). arXiv. https://doi.org/10.48550/arXiv.1803.01422

[5] Ye, Q., Amini, A. A., & Zhou, Q. (2024). Federated Learning of Generalized Linear Causal Networks. *IEEE Transactions on Pattern Analysis and Machine Intelligence*,*46*(10),6623–6636. https://doi.org/10.1109/TPAMI.2024.3381860

[6] Alduais, F. (2022). Textual analysis of the annual report and corporate performance: Evidence from China. Journal of Financial Reporting and Accounting, 22(5), 1221–1252.

[7] DataScienceSphere. (2025). Log Transformation, Min Max Scaling and Standard Scaling in Machine Learning. Medium. https://medium.com/@datasciencejourney100_83560/feature-transformation-bb3db66fa4fe

[8] Xu, P.-F., Lin, S., Zheng, Q.-Z., & Tang, M.-L. (2025). Learning Gaussian Bayesian Network from Censored Data Subject to Limit of Detection by the Structural EM Algorithm.Mathematics,13(9). https://doi.org/10.3390/math13091482

[9] Ng, I., & Zhang, K. (2021). Towards Federated Bayesian Network Structure Learning with Continuous Optimization.arXiv.Org. https://arxiv.org/abs/2110.09356v2

[10] Sutton, R. S., & Barto, A. G. (2018). Reinforcement learning: An introduction, 2nd ed (pp. xxii, 526). The MIT Press.